

# 第四章 向量与矩阵的范数

本章数域  $\mathbb{F}$  指实数域  $\mathbb{R}$  或复数域  $\mathbb{C}$ .

## 4.1 向量范数

定义

定义 (向量范数)

设  $V$  是  $\mathbb{F}$  上的线性空间.  $V$  上的实值函数

$$\|\cdot\| : V \rightarrow \mathbb{R}^+$$

称为  $V$  上的一个范数, 如果它满足

(1) 正定性: 对任意非零向量  $x$ ,  $\|x\| > 0$ .

(2) 正齐性: 对任意向量  $x$  及任意数  $k$ ,  $\|xk\| = \|x\| |k|$ .

(3) 三角不等式: 对任意两个向量  $x$  和  $y$ ,  $\|x + y\| \leq \|x\| + \|y\|$ .

## 定理 (向量范数的性质)

$$(1) \quad \|0\| = 0.$$

$$(2) \quad \|-x\| = \|x\|.$$

$$(3) \quad \|x - y\| \geq |\|x\| - \|y\||.$$

$$(4) \quad \|x + y\| \geq |\|x\| - \|y\||.$$

## 例 (内积空间中向量的长度是范数)

以下约定, 凡是说到长度, 都是专指内积空间中由内积定义的长度.

问题: 范数何时是长度?

定理（范数何时是长度？）

范数是长度的充要条件是它满足平行四边形公式，即：

设  $\|\cdot\|$  是线性空间  $V$  上的一个范数. 如果它满足平行四边形公式，即对任意两个向量  $x$  和  $y$ ,

$$\|x+y\|^2 + \|x-y\|^2 = 2(\|x\|^2 + \|y\|^2),$$

则存在唯一的  $V$  上的一个内积  $\langle \cdot, \cdot \rangle$ ，使得对任意向量  $x$

$$\|x\| = \sqrt{\langle x, x \rangle}.$$

例 ( $\mathbb{C}^n$  上的  $p$ -范数)

对任意  $x \in \mathbb{C}^n$ ,  $1 \leq p \leq \infty$ , 定义

$$\|x\|_p = \begin{cases} \left( |x_1|^p + |x_2|^p + \cdots + |x_n|^p \right)^{\frac{1}{p}}, & 1 \leq p < \infty, \\ \max \{|x_1|, |x_2|, \dots, |x_n|\}, & p = \infty. \end{cases}$$

可以证明,  $\|\cdot\|_p$  是  $\mathbb{C}^n$  上的范数, 称为  $p$ -范数.

以下事实

$$\lim_{p \rightarrow \infty} \left( |x_1|^p + |x_2|^p + \cdots + |x_n|^p \right)^{\frac{1}{p}} = \max \{|x_1|, |x_2|, \dots, |x_n|\}$$

解释了记号  $\|\cdot\|_\infty$  的合理性.


证:  $p$ -范数是范数

(1) (2) 易证

$$(3). \|x+y\|_p \leq \|x\|_p + \|y\|_p$$

$$\text{即 } \left( \sum_{i=1}^n |x_i+y_i|^p \right)^{\frac{1}{p}} \leq \left( \sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}} + \left( \sum_{i=1}^n |y_i|^p \right)^{\frac{1}{p}}$$

引理(凸组合)



$x_1$ 和 $x_2$ 的凸组合为线段  $x_1x_2$

$f(x_1)$ 和 $f(x_2)$  ---  $f(x_1)f(x_2)$

用泰勒公式可证:


$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n f(x_i) \lambda_i$$

$f''(x) > 0 \Rightarrow f(x)$  是下凸的.

凸组合:  $r$ 个向量  $\{v_1, v_2, \dots, v_r\}$

其凸组合  $\sum_{i=1}^r v_i \lambda_i$ , 其中

$$0 \leq \lambda_i \leq 1, \sum_{i=1}^r \lambda_i = 1 \quad (\text{证明, 考})$$



阴影部分为凸组合  
可以落在此空间.

回到(3). 两边同时除左边, 得  $1 \leq \left[ \frac{\sum_i a_i^p}{\sum_k (a_k+b_k)^p} \right]^{\frac{1}{p}} + \left[ \frac{\sum_i b_i^p}{\sum_k (a_k+b_k)^p} \right]^{\frac{1}{p}}$

$$\begin{aligned} \frac{\sum_i a_i^p}{\sum_k (a_k+b_k)^p} &= \sum_i \frac{a_i^p}{\sum_k (a_k+b_k)^p} \\ &= \sum_i \frac{(a_i+b_i)^p}{\sum_k (a_k+b_k)^p} \cdot \frac{a_i^p}{(a_i+b_i)^p} \end{aligned}$$

构造出一个  $\lambda$  来

$$= \sum_i \underbrace{\frac{(a_i+b_i)^p}{\sum_k (a_k+b_k)^p}}_{\lambda_i} \cdot \left( \frac{a_i}{a_i+b_i} \right)^p \geq \left( \sum_i \lambda_i \frac{a_i}{a_i+b_i} \right)^p \quad (\text{引理})$$

设  $x_i = \frac{a_i}{a_i+b_i}$ ,  $f(x) = x^p$

$f''(x) \geq 0$ , 当  $p \geq 2$  时, 下凸

$$\sqrt[p]{\lambda} = \left[ \sum_i \frac{(a_i+b_i)^p}{\sum_k (a_k+b_k)^p} \cdot \left( \frac{a_i}{a_i+b_i} \right)^p \right]^{\frac{1}{p}} + \left[ \sum_i \frac{(a_i+b_i)^p}{\sum_k (a_k+b_k)^p} \cdot \left( \frac{b_i}{a_i+b_i} \right)^p \right]^{\frac{1}{p}}$$

$$\geq \left[ \left( \sum_i \lambda_i \frac{a_i}{a_i+b_i} \right)^p \right]^{\frac{1}{p}} + \left[ \left( \sum_i \lambda_i \frac{b_i}{a_i+b_i} \right)^p \right]^{\frac{1}{p}}$$

$$= \sum_i \lambda_i \frac{a_i}{a_i+b_i} + \sum_i \lambda_i \frac{b_i}{a_i+b_i}$$

$$= \sum_i \lambda_i \left( \frac{a_i}{a_i+b_i} + \frac{b_i}{a_i+b_i} \right)$$

$$= \sum_i \lambda_i = 1$$

例（ $p$ -范数中只有 2-范数是长度）

只需证明，当  $p \neq 2$  时， $p$ -范数不满足平行四边形公式。例如，在  $\mathbb{C}^2$  中，取

$$x = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad y = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

分别计算四个范数

$$\|x\|_p = \|y\|_p = 1, \quad \|x + y\|_p = \|x - y\|_p = 2^{\frac{1}{p}}.$$

$$\|x\|_\infty = \|y\|_\infty = \|x + y\|_\infty = \|x - y\|_\infty = 1.$$

易见，

$$\left(\|x + y\|_p\right)^2 + \left(\|x - y\|_p\right)^2 \neq 2\left(\|x\|_p^2 + \|y\|_p^2\right).$$

问题：既然已经有了长度，为什么还要考虑不是长度的范数？

引入范数使得我们可以考虑两个向量的距离。而距离好处有两个，分别是定性的和定量的。定性的方面是可以考虑极限，进而引入连续，导数与积分等数学分析的方法。定量的方面是可以为最优逼近问题提供逼近性能指标。定性的角度来说，各种范数的作用是等价的（范数的等价性）；但就提供符合实际需求的逼近性能指标来说，不同的范数起着不同的作用，给出的“最优解”也不同。



定义 (范数定义距离)

设  $\|\cdot\|$  是向量空间  $V$  上的范数. 对任意  $x, y \in V$ , 记

$d(x, y) = \|x - y\|$ . 如此决定了  $V$  上的二元函数

$$d(\cdot, \cdot) : V \times V \rightarrow \mathbb{R}^+,$$

称为由范数  $\|\cdot\|$  定义的距离.

例 (中位数作为最小一乘估计)

范数的等价性

中位数.

数组  $\{x_1, x_2, \dots, x_n\}$  的有序排列  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

$$\text{中位数} = \begin{cases} x_{(\frac{n+1}{2})} & , n \text{ 为奇数} \\ [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & , n \text{ 为偶数} \end{cases}$$

(注) 算术平均作为最小二乘估计:

$$\sum_{i=1}^n |x_i - c|^2 \rightarrow \min, \text{ 当 } c \text{ 是算术平均}$$

2 范数意义下的最优解

$$f(c) = \sum_{i=1}^n (x_i - c)^2 = \left\| \begin{bmatrix} x_1 - c \\ x_2 - c \\ \vdots \\ x_n - c \end{bmatrix} \right\|_2$$



$$= \|x - \mathbf{1} \cdot c\|, \quad \mathbf{1} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$$

$x$  在  $\vec{c}$  上的正交投影.

(几何观点.)

中位数的极值刻画:

$$\sum_{i=1}^n |x_i - c| \rightarrow \min, \text{ 当 } c \text{ 是中位数,}$$


1 范数意义下的最优解

$$\text{证: } \sum_{i=1}^n |x_{(i)} - \hat{x}| \leq \sum_{i=1}^n |x_{(i)} - c|, \quad \forall c$$

$$\Rightarrow x_{(n)} - x_{(1)} \leq |x_{(1)} - \hat{x}| + |x_{(n)} - \hat{x}| \leq |x_{(1)} - c| + |x_{(n)} - c|$$

$$x_{(n-1)} - x_{(2)} \leq |x_{(2)} - \hat{x}| + |x_{(n-1)} - \hat{x}| \leq |x_{(2)} - c| + |x_{(n-1)} - c|$$

几何意义是两点间距,  $\because$  若  $c$  在两点间, 可以取等, 否则必大于两点间距.



求谈.

比较  $p=1$  和  $p=2$ .

$p=2$  最大的好处是光滑的, 可以利用求导

$\bar{x} = \sum_{i=1}^n \frac{1}{n} x_i$ ,  $x_i$  有相同概率影响  $\bar{x}$ . 若有很大噪声会影响很大.  
所以说不稳健.

$p=1$  是稳健的, 可以很大程度的去除噪声.

范数等价性:

有限维空间中的任意两个范数  $\|\cdot\|_2$ ,  $\|\cdot\|_p$ , 存在  $m, M$ ,

$$m\|x\|_p \leq \|x\|_2 \leq M\|x\|_p. \quad (\|\cdot\|_2, \|\cdot\|_p \text{ 可相互控制})$$

等价性是说范数对研究极限的效果是一样的,

但作为评价指标性能是不同的.

例:  $\|\cdot\|$ ,  $\|\cdot\|_2$ .

$$\textcircled{1} \quad x = I \cdot x = [e_1, e_2, \dots, e_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \sum_i e_i x_i$$

$$\|x\| = \left\| \sum_i e_i x_i \right\| \stackrel{(1)}{\leq} \sum_i \|e_i x_i\| \stackrel{(2)}{=} \sum_i \|e_i\| \cdot |x_i| \leq \sqrt{\sum_i \|e_i\|^2} \cdot \|x\|_2 \quad (\text{柯西不等式})$$

$$\textcircled{2} \quad \|x\|: \mathbb{C}^n \rightarrow \mathbb{R}, \quad \|x\| \text{ 是 } \mathbb{C} \text{ 上的连续函数, 则 } \lim_{x \rightarrow p} \|x\| = \|p\|$$

$S = \{x \mid \|x\|_2 = 1\}$  是有界闭集, 定理: 有界闭集上的连续函数一定有最大值.  
( $M/m$ )

$$0 \leq m \leq \|x\| \leq M. \quad \text{则 } m \leq \underbrace{\left\| \frac{x}{\|x\|_2} \right\|}_{\text{单位化}} \leq M$$

## 4.2 矩阵范数

定义 (矩阵范数)

设对任意的正整数  $m$  和  $n$ ，及任意的  $m \times n$  矩阵  $A$ ，都有一个对应的实数  $\|A\|$ 。若该对应关系满足

(1) 正定性：对任意  $m \times n$  的任意非零矩阵  $A$ ，都有  $\|A\| > 0$ 。

(2) 正齐性：对任意矩阵  $A$  及数  $k$ ， $\|kA\| = |k| \|A\|$ 。

(3) 三角不等式 (加法相容性)：若矩阵  $A$  和  $B$  可以相加，则  $\|A + B\| \leq \|A\| + \|B\|$ 。

(4) 乘法相容性：若矩阵  $A$  和  $B$  可以相乘，则  $\|AB\| \leq \|A\| \|B\|$

则称对应关系  $\|\cdot\|$  是一个矩阵范数。

其实, 严格地说,  $\|\cdot\|$  应理解为一个映射

$$\|\cdot\| : \bigcup_{m,n \geq 1} \mathbb{F}^{m \times n} \rightarrow \mathbb{R} .$$

例 (Hilbert-Schmidt 范数)

## 向量范数导出矩阵范数

观察：由于具体向量  $x \in \mathbb{F}^n$  其实也就是  $n \times 1$  的矩阵，因此任一矩阵范数也就同时给出了标准向量空间  $\mathbb{F}^n$ ，也就是  $\mathbb{F}^{n \times 1}$ ， $n = 1, 2, \dots$ ，上的向量范数.

反之，也可以从已知的标准向量空间  $\mathbb{F}^n$ ， $n = 1, 2, \dots$ ，上的向量范数，决定出一个矩阵范数.

## 定理 (向量范数诱导矩阵范数)

设对任意的正整数  $k = 1, 2, \dots$ , 给定了标准向量空间  $\mathbb{F}^k$  上的向量范数  $\|\cdot\|_{\alpha_k}$ . 对任意的正整数  $m$  和  $n$ , 及任意的  $m \times n$  矩阵  $A$ , 定义

$$\|A\| := \max \left\{ \frac{\|Ax\|_{\alpha_m}}{\|x\|_{\alpha_n}} : x \in \mathbb{F}^n, x \neq 0 \right\} = \max \left\{ \|Ax\|_{\alpha_m} : x \in \mathbb{F}^n, \|x\|_{\alpha_n} = 1 \right\}$$

则  $\|\cdot\|$  为一矩阵范数, 称为由向量范数  $\|\cdot\|_{\alpha_k}$ ,  $k = 1, 2, \dots$ , 导出的矩阵范数.

注意, 当  $\|\cdot\|_{\alpha_1}$  是  $\mathbb{F}^1$  (即实数域或复数域) 上的绝对值时, 如上导出的矩阵范数限制在  $\mathbb{F}^k = \mathbb{F}^{k \times 1}$  上, 才与  $\|\cdot\|_{\alpha_k}$  重合.

注（向量范数诱导矩阵范数的几何意义）

最大增益(信号与系统的观点)； 长度最大放大率(几何的观点)。

因此矩阵范数是许多系统设计指标的要利用的工具。

例（向量的  $p$ -范数导出的矩阵范数）



## 4.3 范数应用举例

矩阵值序列与函数

矩阵指数函数

范数控制特征值

可逆性的范数条件

矩阵的条件数